

Soğuk Savaş Dönemi Yasama Dinamikleri: 1984 Kongre Verisi Üzerine İstatistiksel Bir İnceleme

Emirhan Kunt

Öğrenci Numarası: 173323054

Giriş: 1984 Yılında Dünyanın Jeopolitik Dengeleri ve ABD'nin Soğuk Savaş Stratejisi

1984 yılı, İkinci Dünya Savaşı sonrasında şekillenen iki kutuplu dünya düzeninin ve Soğuk Savaş geriliminin en tepe noktalarından birini temsil etmektedir. 1970'lerin görece yumuşama (detant) döneminin ardından, 1979'da Sovyetler Birliği'nin Afganistan'ı işgaliyle yeniden tırmanışa geçen küresel rekabet, 1980'lerin ortasında askeri, ideolojik ve ekonomik bir güç savaşına dönüşmüştür. Bu dönemde küresel siyasetin ana belirleyicisi, bir yanda ekonomik durgunluk ve liderlik krizleriyle boğuşan Sovyetler Birliği (SSCB), diğer yanda ise Ronald Reagan liderliğinde agresif bir anti-komünist doktrin benimseyen Amerika Birleşik Devletleri olmuştur. 1984 yılı, bu iki süper gücün doğrudan bir çatışmadan kaçınırken, dünyanın dört bir yanında ve hatta uzayda üstünlük kurma mücadelesinin zirveye ulaştığı kritik bir kesittir.

Ronald Reagan yönetimindeki ABD, 1984 yılına gelindiğinde dış politikasını Sovyet genişlemeciliğini sadece çevrelemek (containment) değil, onu doğrudan geriletmek (rollback) üzerine kurmuştur. Reagan'ın Sovyetler Birliği'ni "Şer İmparatorluğu" (Evil Empire) olarak nitelendirmesiyle başlayan bu yeni dönem, ABD'nin askeri bütçesinde devasa bir artışı beraberinde getirmiştir. 1984'ün jeopolitik atmosferine damgasını vuran en önemli unsurlardan biri, kamuoyunda "Yıldız Savaşları" olarak bilinen Stratejik Savunma Girişimi (SDI) ve nükleer caydırıcılığı artırmayı hedefleyen MX füzeleri gibi ileri teknoloji askeri projelerdir. Uzay kalkanı projesiyle SSCB'nin nükleer tehdidini işlevsiz kılmayı amaçlayan Washington, Moskova'yı mühimmat ve teknoloji yarışında ekonomik olarak iflasa sürükleyecek bir strateji izlemiştir. Aynı zamanda bu askeri tırmanış, iki blok arasındaki diplomatik köprüleri kopma noktasına getirmiş; Sovyetler Birliği ve müttefiklerinin 1984 Los Angeles Olimpiyatları'nı boyot etmesiyle gerilim kültürel ve sosyal alana da taşınmıştır.

Dünyadaki genel duruma bakıldığında, iki süper gücün rekabeti doğrudan bir savaşa yol açmasa da çevre ülkelerde yıkıcı ve kanlı vekalet savaşları (proxy wars) şeklinde tezahür etmiştir. 1984 yılında Orta Amerika, bu ideolojik cephe hatlarının en sıcak bölgelerinden biri haline gelmiştir. ABD, Nikaragua'daki Marksist Sandinista yönetimine karşı savaşan Kontraları el altından desteklerken, El Salvador'daki sağcı hükümete de solcu gerillalarla mücadele etmesi için yoğun askeri ve finansal yardımlar aktarmıştır. Benzer

şekilde, Afrika boynuzunda ve Asya'da komünizm karşıtı yerel güçlerin desteklenmesi, "Reagan Doktrini"nin küresel çapta hayata geçirilmesinin birer parçası olmuştur. SSCB tarafında ise, arka arkaya gelen yaşlı liderlerin (Andropov ve ardından gelen Çernenko) yarattığı yönetim boşluğu ve Afganistan'daki savaşın getirdiği devasa ekonomik yük, rejimin küresel hamlelerine ket vurmaya başlamıştır.

ABD iç siyasetinde ise dış politikadaki bu şahin tutum, Washington'daki yasama faaliyetlerinde ve bütçe görüşmelerinde derin ideolojik kutuplaşmalara yol açmıştır. Reagan yönetimi askeri yardımları ve savunma bütçesini artırmak için agresif bir politika izlerken, Kongre içindeki muhalefet zaman zaman bu fonların sınırlandırılması veya yerel sosyal programlara (sağlık ve eğitim bütçesi gibi) kaydırılması yönünde sert bir direnç göstermiştir. Sonuç olarak, 1984 yılı küresel çapta Soğuk Savaş diplomasisinin en gergin, askeri harcamaların en yüksek ve ideolojik sınırların en keskin olduğu bir dönem olarak tarihe geçmiştir. Bu dönemi anlamak, sadece askeri güç dengelerini değil, aynı zamanda devletlerin iç ve dış politik kararlarının ardında yatan ideolojik ve ekonomik motivasyonları analiz etmeyi zorunlu kılmaktadır.


Veriye Kısa Bir Bakış

Bu çalışmada kullanılan veri kümesi, makine öğrenmesi ve siyaset bilimi literatüründe klasik bir test alanı olarak kabul edilen ve UCI Machine Learning Repository'de yer alan 1984 ABD Kongre Oylama Kayıtları veri setidir. Veri seti, Amerika Birleşik Devletleri Kongresi'nin 1984 yılındaki ikinci oturumunda oylanan on altı kritik yasa tasarısını

Veri Seti Sözlüğü: Değişkenler ve Temsil Ettikleri Gerçek Yasalar

Değişken (Kod) Adı	1984 ABD Kongresi Yasa Tasarısı (Tam Adı)
parti	Parti Aidiyeti (Hedef Değişken: Demokrat / Cumhuriyetçi)
engelli_bebekler	Engelli Bebeklere Tıbbi Müdahale Yasası (Handicapped Infants)
su_projesi	Su Projeleri Maliyet Paylaşımı (Water Project Cost Sharing)
butce_tasarisi	Bütçe Kararı Kabulü (Adoption of the Budget Resolution)
doktor_ucreti	Doktor Ücretlerinin Dondurulması (Physician Fee Freeze)
el_salvador	El Salvador'daki Askeri Rejime Yardım (El Salvador Aid)
okulda_din	Devlet Okullarında Dini Gruplara İzin (Religious Groups in Schools)
anti_uydu	Anti-Uydu Silah Testlerinin Yasaklanması (Anti-Satellite Test Ban)
nikaragua	Nikaragua'daki Kontra İsyancılarına Yardım (Aid to Nicaraguan Contras)
mx_fuzesi	MX Nükleer Füzesi Üretimi (MX Missile)
gocmenlik	Göçmenlik ve Sınır Kontrol Yasası (Immigration)
sentetik_yakit	Sentetik Yakıt Şirketleri Bütçe Kesintisi (Synfuels Corp. Cutback)
egitim_butcesi	Eğitim Bütçesi ve Harcamaları (Education Spending)
cevre_davasi	Çevre Kirliliği Davaları ve Fonu (Superfund Right to Sue)
suc_yasasi	Kapsamlı Suç Kontrol Yasası (Crime)
gumruksuz_ihracat	Gümrüksüz İhracat Ayrıcalıkları (Duty Free Exports)
guney_afrika	Güney Afrika'daki Apartheid Rejimine Ambargo (South Africa Act)

ve bu tasarılar karşısında milletvekillerinin sergilediği oylama davranışlarını içermektedir. İstatistiki modelleme açısından çok boyutlu kategorik özneliklere sahip bir ikili sınıflandırma problemi sunan bu çalışmada temel amaç, kongre üyelerinin oylama kalıplarından yola çıkarak siyasi parti aidiyetlerini tahmin etmektir.



Veri setinde toplam 435 kongre üyesine ait oylama kaydı bulunmakta olup, bu üyelerin 267'si Demokrat Parti, 168'i ise Cumhuriyetçi Parti mensubudur. Sınıflar arasındaki bu dağılım, veri setinin algoritmaları manipüle edecek düzeyde radikal bir dengesizliğe sahip olmadığını ve istatistiksel analizler için oldukça sağlıklı bir zemin sunduğunu göstermektedir.

Modellemede bağımsız değişken olarak kullanılan on altı yasa tasarısı, dönemin ideolojik çatışmalarını yansıtan geniş bir yelpazeye sahiptir. Bu tasarılar arasında Handikaplı Çocuklar Yasası ve Doktor Muayene Ücretlerinin Dondurulması gibi iç siyaset ve bütçe politikalarının yanı sıra, El Salvador Askeri Yardımı, Nikaragua Kontralarına Yardım ve MX Füzesi Projesi gibi Soğuk Savaş döneminin sert dış politika kararları da yer almaktadır. Orijinal veri setinde milletvekillerinin oyları evet, hayır ve çekimser ya da belirsiz anlamlarına gelen harf veya işaretlerle tutulmuştur. Ancak makine öğrenmesi algoritmalarının bu verileri matematiksel olarak işleyebilmesi ve katsayı hesaplamaları yapabilmesi için yapı simetrik bir sayısal düzleme dönüştürülmüştür. Bu dönüşümde hayır oyları -1, evet oyları 1, çekimser veya bilinmeyen oyları ise 0 olarak kodlanmıştır.

Uygulanan bu veri ön işleme stratejisi, oyların yönünü ve şiddetini korurken, 0 değerinin bir nötrlük ifadesi olarak algoritmalar tarafından tarafsız bir ağırlıkla işlenmesine olanak tanımıştır. Ayrıca veri setindeki belirsiz veya boş değerler, istatistikteki sıradan kayıp veriler gibi değerlendirilip silinmemiş veya yapay ortalamalarla doldurulmamıştır. Siyaset sosyolojisi açısından bir vekilin oylamaya katılmaması veya çekimser kalması stratejik bir tercih olduğundan, bu durum doğrudan 0 değeriyle sisteme dahil edilmiştir. Verinin bu dürüst yapısının korunması, geliştirilen modellerin sadece evet veya hayır oylarını değil, aynı zamanda meclis içi disiplin

firelerini ve siyasi sorumluluktan kaçma hamlelerini de matematiksel birer girdi olarak öğrenmesini sağlamıştır.

Veri Ön İşleme ve Hedef Değişkenin Hazırlanması

Makine öğrenmesi modellerinin ham metin verileri üzerinde işlem yapamaması nedeniyle, analiz öncesinde veri setinin sayısal bir forma dönüştürülmesi gerekmiştir. Orijinal verideki evet (y), hayır (n) ve çekimser (?) oyları, Pandas kütüphanesi kullanılarak .replace() fonksiyonu yardımıyla sırasıyla 1, -1 ve 0 değerlerine dönüştürülmüştür. Bu aşamada özellikle kategorik verilerin analizinde sıkça düşülen "etiket kayması" tuzağına karşı dikkatli olunmuştur. Standart çapraz tablo (crosstab) fonksiyonlarının verileri alfabetik sıraya dizmesi nedeniyle oluşabilecek yanlış etiketlemeler, value_counts() fonksiyonu ile teyit edilerek önlenmiş ve dönüşüm işlemi manuel bir sözlük (dictionary) yapısıyla sabitlenmiştir.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

# 1. Veriyi Okuma
dosya_yolu = r"C:\Users\Emirhan Kunt\Desktop\Programlama\Python Klasörü\data\housevotes84.csv"
data = pd.read_csv(dosya_yolu)

sutunlar = [
    'parti', 'engelli_bebekler', 'su_projesi', 'butce_tasarisi', 'doktor_ucreti',
    'el_salvador', 'okulda_din', 'anti_uydu', 'nikaragua', 'mx_fuzesi',
    'gocmenlik', 'sentetik_yakit', 'egitim_butcesi', 'cevre_davasi',
    'suc_yasasi', 'gumruksuz_ihracat', 'guney_afrika'
]

data.columns = sutunlar

# 2. Bağımlı (y) ve Bağımsız (x) Değişkenleri Ayırma
y_ham = data.iloc[:, 0] # İlk sütun (Partiler)
x_ham = data.iloc[:, 1:] # Geri kalanlar (Oylar)

# 3. Kusursuz Encoding İşlemi
le = LabelEncoder()
y = le.fit_transform(y_ham).reshape(-1, 1)

# x (Oylar) için harfleri sayılara çevirip, sütunların sayısal (int) olmasını garanti altına alıyoruz.
x = x_ham.replace({'y': 1, 'n': -1, '?': 0}).astype(int)

# 4. Veriyi Parçalama
X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=34)
```

Veri seti sayısal bir matrise dönüştürüldükten sonra, algoritmaların ezberlemesini (overfitting) engellemek ve gerçek dünya performanslarını ölçebilmek amacıyla veri bölünmüştür (Train-Test Split). Toplam 435 vekilin yer aldığı veri setinin %80'i modellerin eğitimi için ayrılırken, kalan %20'si algoritmaların daha önce hiç görmediği bir test ortamı olarak ayrılmıştır. Bölünme işlemi sırasında sonuçların tekrarlanabilir olması için rastgelelik sabiti (random_state=34) kullanılmıştır.

Makine Öğrenmesi Modellerinin Kurulması

Analiz kapsamında, vekillerin oylama davranışlarından parti aidiyetlerini tahmin etmek üzere geniş çaplı bir modelleme stratejisi izlenmiştir. Veri seti üzerinde sadece tek bir yaklaşıma bağlı kalmamak adına; ağaç tabanlı modeller (Random Forest, Gradient Boosting, CART), mesafe tabanlı modeller (KNN), olasılıksal modeller (Naive Bayes), yapay sinir ağları (MLP) ve doğrusal modellerden (Lojistik Regresyon, Linear SVM) oluşan **9 farklı makine öğrenmesi algoritması** tanımlanarak birbiriyle yarışdırılmıştır.

```
# 2. MODEL TANIMLAMA
from sklearn.svm import SVC
from sklearn.neural_network import MLPClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import GaussianNB
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, f1_score

modeller = {
    "Linear SVM": SVC(kernel="linear"),
    "RBF SVM": SVC(kernel="rbf"),
    "Yapay Sinir Ağları (MLP)": MLPClassifier(max_iter=1000, random_state=34),
    "Karar Ağacı (CART)": DecisionTreeClassifier(random_state=34),
    "Random Forest": RandomForestClassifier(random_state=34),
    "Gradient Boosting": GradientBoostingClassifier(random_state=34),
    "Lojistik Regresyon": LogisticRegression(solver="liblinear"),
    "Naive Bayes": GaussianNB(),
    "K-En Yakın Komşu (KNN)": KNeighborsClassifier()
}
```

Veri setindeki tüm bağımsız değişkenler (yasalar) aynı ölçekte (-1, 0, 1) olduğu için, bu projede standartlaştırma (StandardScaler) adımına ihtiyaç duyulmamıştır. Birim farklılıklarının olmaması, modellerin doğrudan ham katsayılar üzerinden eğitilmesine olanak tanımıştır. Tanımlanan bu model cephaneliği, eğitim seti (X_train, y_train) kullanılarak eğitilmiş ve test seti üzerindeki performansları ölçülmüştür.

Makine Öğrenmesi Algoritmalarının Eğitilmesi ve Karşılaştırılması

Tanımlanan dokuz farklı makine öğrenmesi algoritmasının performanslarını objektif, adil ve yalıtılmış bir ortamda kıyaslayabilmek için otomatize edilmiş bir eğitim ve test döngüsü (loop) inşa edilmiştir. Veri biliminde çoklu model denemelerinin manuel olarak yapılması hem kod tekrarına yol açmakta hem de test koşullarında tutarsızlık riski yaratmaktadır. Bu riskleri ortadan kaldırmak amacıyla, modeller bir sözlük (dictionary) yapısı içinde tutulmuş ve bir for döngüsü yardımıyla sırasıyla sahaya sürülmüştür.

```
# 3. KARŞILAŞTIRMA DÖNGÜSÜ
sonuclar = []

for isim, model in modeller.items():
    # Modeli eğit (.fit)
    model.fit(X_train, y_train)
    # Test seti ile tahmin yap (.predict)
    tahminler = model.predict(X_test)

    # Başarı metriklerini hesapla
    acc = accuracy_score(y_test, tahminler)
    f1 = f1_score(y_test, tahminler)

    # Sonuç listesine ekle
    sonuclar.append({"Model": isim, "Doğruluk Oranı": round(acc, 4), "F1 Skoru": round(f1, 4)})
```

Döngünün ilk aşamasında, her bir algoritma veri setinin %80'lik kısmını oluşturan eğitim seti (X_train, y_train) ile beslenerek öğrenme sürecine (.fit) sokulmuştur. Bu aşamada algoritmalar; destek vektör makineleri için hiper-düzlemler çizerek, ağaç tabanlı modeller için bilgi kazancı (information gain) hesaplayarak veya olasılıksal modeller için koşullu olasılıkları değerlendirerek, vekillerin yasa tasarılarına verdikleri oylar ile siyasi parti kimlikleri arasındaki gizli matematiksel örüntüleri (pattern) keşfetmiştir.

Öğrenme süreci tamamlanan modeller, aşırı öğrenme (overfitting) tuzağına düşüp düşmediklerini kanıtlamak üzere döngünün ikinci aşaması olan test fazına geçirilmiştir. Algoritmalara, daha önce hiç karşılaşmadıkları ve parti etiketleri gizlenmiş olan %20'lik test seti (X_test) verilmiş ve sadece oylama davranışlarına bakarak vekillerin partilerini tahmin etmeleri (.predict) istenmiştir.

Modellerin bu bilinmeyen veri üzerindeki başarılarını tek boyutlu bir bakış açısıyla değerlendirmemek adına, iki kritik istatistiksel metrik bir arada kullanılmıştır:

- **Doğruluk Oranı (Accuracy):** Modelin yaptığı tüm tahminler içinde doğru bildiklerinin genel yüzdesini ifade eder. Veri setimiz radikal bir dengesizliğe sahip olmadığı için temel başarı göstergesi olarak kabul edilmiştir.
- **F1 Skoru (F1-Score):** Kesinlik (Precision) ve Duyarlılık (Recall) değerlerinin harmonik ortalamasıdır. Sadece çoğunluk sınıfını (Demokratlar) değil, her iki partiyi de eşit hassasiyetle ayırt edip edemediğimizi matematiksel olarak garanti altına almak için kullanılmıştır.

Hesaplanan bu metrikler, karşılaştırmalı analizin daha okunaklı ve bilimsel standartlara uygun olması amacıyla virgülden sonra dört basamağa yuvarlanmış (round) ve nihai sonuç tablosunu oluşturmak üzere yapılandırılmış bir veri listesine aktarılmıştır.

Algoritmik Performansların Yapılandırılması ve Nihai Sonuç Tablosu

Eğitim ve test döngüsünün başarıyla tamamlanmasının ardından, modellerin ürettiği ham performans metriklerinin bilimsel bir rapora uygun, analitik ve okunabilir bir

formata dönüştürülmesi aşamasına geçilmiştir. Bu doğrultuda, bir önceki adımda döngü içerisinde toplanan veri listesi, veri biliminin temel kütüphanesi olan Pandas kullanılarak iki boyutlu bir yapıya (DataFrame) aktarılmıştır. Veri çerçevesinin kullanımı, sadece görsel bir düzenleme olmanın ötesinde, algoritmaların başarı oranları üzerinde istatistiksel sıralama ve yapısal inceleme yapılmasına olanak tanıyan analitik bir gerekliliktir.

```
# 4. SONUÇLARI SIRALAMA VE GÖSTERME
sonuclar_df = pd.DataFrame(sonuclar)
sonuclar_df = sonuclar_df.sort_values(by="Doğruluk Oranı", ascending=False).reset_index(drop=True)

print("--- 1984 ABD KONGRESİ KUTUPLAŞMA TAHMİNİ SONUÇLARI ---")
print(sonuclar_df)
```

Elde edilen sonuçlar, tabloya rastgele bir dizilimle yansıtılmak yerine rekabetçi bir hiyerarşi sunacak şekilde dizayn edilmiştir. Yarıştırılan tüm makine öğrenmesi algoritmaları, temel performans kriteri olarak belirlenen "Doğruluk Oranı" (Accuracy) metriği baz alınarak, sort_values fonksiyonu ile büyükten küçüğe (azalan - descending) doğru sıralanmıştır. Bu işlem, 1984 ABD Kongresi'ndeki ideolojik kutuplaşmayı en yüksek keskinlikle deşifre eden "şampiyon" algoritmaları doğrudan listenin en üstüne taşımıştır.

```
In [35]: print("--- 1984 ABD KONGRESİ KUTUPLAŞMA TAHMİNİ SONUÇLARI ---")
--- 1984 ABD KONGRESİ KUTUPLAŞMA TAHMİNİ SONUÇLARI ---


In [36]: print(sonuclar_df)
```

	Model	Doğruluk Oranı	F1 Skoru
0	Linear SVM	0.9885	0.9855
1	Yapay Sinir Ağları (MLP)	0.9885	0.9855
2	Lojistik Regresyon	0.9885	0.9855
3	Random Forest	0.9770	0.9706
4	RBF SVM	0.9655	0.9577
5	Naive Bayes	0.9655	0.9552
6	Gradient Boosting	0.9655	0.9577
7	K-En Yakın Komşu (KNN)	0.9540	0.9429
8	Karar Ağacı (CART)	0.9080	0.8919

Son olarak, veri çerçevesinin karmaşıklaşan indeks yapısı reset_index fonksiyonu ile sıfırlanarak temizlenmiş ve elde edilen bu nihai sıralama, çalışmanın özünü yansıtan "1984 ABD KONGRESİ KUTUPLAŞMA TAHMİNİ SONUÇLARI" başlığı altında rapora dökülmüştür. Elde edilecek bu nihai tablo, kurulan 9 farklı makine öğrenmesi modelinin, dönemin siyasi ayrışmasını hangi düzeyde matematikselleştirebildiğinin en somut ve kesin kanıtı olarak raporun merkezinde yer almaktadır.

Lojistik Regresyon Katsayılarının Sosyo-Politik Yorumu ve Özellik Önem Analizi

Lojistik Regresyon algoritmasının ürettiği β katsayıları (özellik önem dereceleri) sadece matematiksel birer ağırlık olmanın ötesinde, 1984 yılındaki Amerikan Kongresi'nin ideolojik fay hatlarını gösteren bir röntgen niteliğindedir. Grafikteki her bir çubuğun yönü ve uzunluğu, o yasa tasarısının bir vekilin siyasi kimliğini ele vermekteki gücünü temsil etmektedir. Modelin elde ettiği %99'luk yüksek başarı oranı, aslında bu katsayıların verideki gizli sosyolojik kalıpları kusursuz bir şekilde yakalamasından kaynaklanmaktadır.



Elde edilen katsayı grafiği üç ana başlık altında incelendiğinde, dönemin meclis dinamiklerine dair çarpıcı sonuçlar ortaya çıkmaktadır:

A. En Yüksek Katsayılı Ayırıcılar: "Cüzdan Korkusu" ve İç Siyaset

Grafikteki en uzun çubuklara (mutlak değerce en büyük katsayılarla) bakıldığında, "Doktor Muayene Ücretlerinin Dondurulması" (Medicare) tasarısının meclisi en keskin bölen yasa olduğu görülmektedir. Yasaya yakından bakmak gerekirse; Amerika'da yaşlı ve engellilerin sağlık masraflarını karşılayan devlet destekli "Medicare" adında dev bir sigorta sistemi var. 1980'lerin başında doktorların hastane ve muayene ücretleri enflasyonla birlikte kontrolden çıkıp inanılmaz bir hızla artmaya başlıyor. Devletin sağlık bütçesi bu faturaları ödemekte zorlanıp dibi görmeye başlıyor.

Bunun üzerine hükümet (Ronald Reagan yönetimi), federal bütçe açığını kapatmak için çok sert bir yasa tasarısı hazırlıyor: **Doktorlara devlet tarafından ödenen muayene ve**

tedavi ücretlerine 15 aylık bir "dondurma" (freeze) getiriliyor. Yani tasarı doktorlara özetle şunu söylüyor: "Önümüzdeki 15 ay boyunca devlete kestiğiniz faturalara tek kuruluş zam yapamazsınız, ücretlerinizi tamamen sabitliyoruz."

Lojistik Regresyon algoritması doğası gereği hata yapmaktan kaçınan (açgözlü/greedy) bir yapıya sahiptir. Algoritma veri setini tararken, bu yasada Demokratların %92'sinin blok halinde "Hayır", Cumhuriyetçilerin ise %97'sinin blok halinde "Evet" dediğini fark etmiştir. Sadece 16 vekilin kendi parti çizgisinden saptığı bu "kusursuz ayrışma" (perfect separation) durumu, modelin bu yasaya devasa bir matematiksel ağırlık yüklemesine sebep olmuştur. Siyasi açıdan bunun anlamı nettir: Vekiller, Soğuk Savaş krizlerinden ziyade vatandaşın doğrudan cüzdanına ve sağlık sistemine dokunan konularda kendi seçmenlerini karşılarına almaktan korkmuş ve katı parti disiplinine sığınmışlardır. Model, bir vekilin partisini tahmin ederken en çok bu yasaya bakarak karar vermektedir.

B. Orta Düzey Katsayılar: Dış Politika ve Verideki "Gürültü" (Noise)

1984 yılı Soğuk Savaş'ın zirvesi olmasına rağmen, "El Salvador Askeri Yardımı" veya "Nikaragua Kontralarına Yardım" gibi devasa küresel krizlerin katsayıları, iç siyaset yasalarının gerisinde kalmıştır. Bunun matematiksel sebebi, dış politika tasarılarında partiler arası geçişlerin ve isyan eden vekil sayısının çok daha yüksek olmasıdır. Örneğin El Salvador oylamasında 66 vekil parti çizgisine uymayarak karşı tarafla birlikte oy kullanmıştır. Makine öğrenmesi literatüründe bu durum "gürültü" (noise) olarak adlandırılır. Lojistik Regresyon, bu yasaların üzerine çok fazla bahis oynarsa yanılma payının artacağını matematiksel olarak hesaplamış ve tahmin ağırlığını bu yasalardan çekerek daha güvenli olan iç politika sütunlarına kaydırmıştır. Bu durum, vekillerin uluslararası konularda kendi bireysel vicdanlarına veya lobilerin etkisine daha açık olduğunu kanıtlamaktadır.

C. Sıfıra Yakın Katsayılar: İki Partili (Bipartisan) Uzlaşma Alanları

Grafikte sıfır çizgisine (nötr eksene) çok yakın duran ve çubuğu neredeyse hiç uzamayan "Su Projesi Bütçesi" (Water Project Cost Sharing) gibi yasalar da istatistiksel olarak büyük bir anlam taşımaktadır. Katsayının sıfıra yakın olması, bu yasanın modelin gözünde "işe yaramaz" veya "ayrıştırmacı gücü olmayan" bir değişken olduğunu gösterir. Çünkü bu tür altyapı projelerinde Demokratlar ve Cumhuriyetçiler ideolojik kimliklerini bir kenara bırakıp kendi bölgelerine yatırım çekmek amacıyla benzer (bipartisan) oylar kullanmışlardır. Oylar birbirine karıştığı için algoritma bu sütuna bakarak vekilin partisini tahmin edemeyeceğini anlamış ve bu yasanın matematiksel etkisini sıfırlayarak modelin yanılma riskini bertaraf etmiştir.

Özetle Lojistik Regresyon modeli; hangi yasaların meclisi ikiye böldüğünü, hangi yasalarda vekillerin fire verdiğini ve hangi konularda partiler üstü bir uzlaşma sağlandığını sadece 1, -1 ve 0'ları birbiriyle çarparak deşifre etmiş ve bu muazzam analitik denklemi %99'luk bir başarı metriğiyle taçlandırmıştır.


Yapay Sinir Ağları (MLP): Aşırı Mühendislik ve Kara Kutu Problemi

Eğitim ve test döngüsü sonucunda Çok Katmanlı Algılayıcı (Multi-Layer Perceptron - MLP) tabanlı Yapay Sinir Ağları da %99 gibi istisnai bir doğruluk oranına ulaşarak en başarılı modeller arasında yer almıştır. Ancak, elde edilen bu salt matematiksel başarıya rağmen, Yapay Sinir Ağları bu projenin doğasına, veri yapısına ve sosyo-politik analiz hedeflerine yapısal olarak uygun bulunmamış ve ana model olarak seçilmemiştir. Bu stratejik kararın arkasında veri bilimi literatürüne dayanan üç temel neden bulunmaktadır:

- **Açıklanabilirlik Eksikliği ve "Kara Kutu" (Black-Box) Doğası:** Bu projenin temel amacı sadece bir vekilin partisini tahmin etmek değil, aynı zamanda 1984 meclisindeki ideolojik fay hatlarını deşifre etmektir. Lojistik Regresyon gibi "Beyaz Kutu" (White-Box) modeller, tahminin arkasındaki nedeni katsayılar (β) aracılığıyla şeffafça sunar; Yapay Sinir Ağları "Kara Kutu" prensibiyle çalışır. Veri, gizli katmanlardan (hidden layers) ve doğrusal olmayan aktivasyon fonksiyonlarından geçirilerek bir sonuca ulaşır. Bu karmaşık mimari, "Model bu vekili neden Cumhuriyetçi olarak sınıflandırdı?" sorusuna sosyolojik ve mantıksal bir cevap veremez. Yorumlanabilirliğin (interpretability) %100 olması gereken böylesi politik bir veri setinde, nedenleri gizleyen bir model kullanmak analiz sürecini felce uğratır.
- **Veri Hacmi ve Aşırı Mühendislik (Over-Engineering):** Yapay Sinir Ağları, içindeki binlerce (hatta milyonlarca) ağırlık parametresini (weight) doğru bir şekilde güncelleyebilmek için devasa hacimli (Big Data) veri setlerine ihtiyaç duyar. Sadece 435 satır ve 16 sütundan oluşan, sınıfları oldukça dengeli ve küçük çaplı bu veri setinde bir sinir ağı mimarisi kurmak, akademik tabirle "Aşırı Mühendislik" (Overkill / Over-engineering) yapmaktır. Basit bir denklemle çözülebilecek bir soruna devasa bir hesaplama gücüyle saldırmak, hem işlemci maliyetini artırır hem de optimum çözüm felsefesine aykırıdır.
- **Ockham'ın Usturası ve Doğrusal Ayrılabilirlik:** Bilimsel felsefenin temel prensiplerinden olan Ockham'ın Usturası (Occam's Razor), *"Eşit şartlar altında, en basit açıklama en doğru olanıdır"* der. Lojistik Regresyon sonuçlarından da anlaşıldığı üzere, 1984 Kongre verisi uzayda basit ve düz bir çizgiyle (linearly separable) kusursuzca ayrılabilir. Ortada doğrusal olmayan (non-linear) karmaşık bir problem yokken, Yapay Sinir Ağları gibi non-linear sınırları bükerek çizen algoritmaları kullanmak, modelin eğitim verisini ezberleme (Overfitting) riskini gereksiz yere tırmandırmaktadır.

Kara Kutuya Işık Tutmak: MLP İçin Permütasyon Önemi (Permutation Importance)

Bilindiği üzere Yapay Sinir Ağları (MLP), karmaşık gizli katman (hidden layer) mimarisi sebebiyle özelliklerin doğrudan okunmasına izin vermeyen bir "kara kutu" yapısına sahiptir. Bu sorunu aşmak ve modelin karar mekanizmasını şeffaflaştırmak adına **Permütasyon Önemi (Permutation Feature Importance)** yöntemi kullanılmıştır. Bu algoritma, her bir yasa tasarısının sütunundaki verileri rastgele karıştırarak (gürültü ekleyerek) modelin o yasaya olan bağımlılığını ölçer.



Grafikte görüldüğü üzere, örneğin "Doktor Ücretleri" sütunu manipüle edildiğinde modelin genel doğruluk oranı dramatik bir şekilde düşmektedir (en uzun çubuk). Bu durum, devasa nöron ağının bile, bir vekilin partisini tahmin ederken en çok ağırlığı bütçe ve sağlık alanındaki keskin ayrışmalara verdiğini kanıtlamaktadır. Lojistik Regresyon gibi yönelim (Demokrat/Cumhuriyetçi) belirtemese de bu analiz; sinir ağlarının karmaşık çalışmasına rağmen, 1984 kongresinin basit sosyolojik gerçeklerinden kaçamadığını ispatlamaktadır

Sonuç olarak; Yapay Sinir Ağları her ne kadar test setinde kusursuz bir başarı yakalamış olsa da, sosyo-politik bir çalışmanın gerektirdiği nedensellik ve şeffaflık ilkelerini karşılayamadığı için bu projenin odak noktası olmaktan çıkarılmıştır.

Doğrusal Destek Vektör Makineleri (Linear SVM): Marjin Felsefesi ve Geometrik Ayrışma

Analiz sonucunda Lojistik Regresyon ile birlikte %99'luk zirveyi paylaşan diğer "beyaz kutu" modelimiz Doğrusal Destek Vektör Makineleri (Linear SVM) olmuştur. Her ne kadar iki algoritma da benzer başarı oranları üretse de, veriye yaklaşım biçimleri ve


temel matematiksel felsefeleri birbirinden tamamen farklıdır. Lojistik Regresyon problemi olasılıksal (probabilistic) bir yaklaşımla çözerken, SVM problemi tamamen "geometrik" bir uzay denklemi olarak ele alır.

Linear SVM Nasıl Çalışır?

SVM'in temel amacı, veri uzayındaki iki sınıfı (Demokratlar ve Cumhuriyetçiler) birbirinden ayıran herhangi bir doğru çizmek değil; bu iki sınıf arasındaki en geniş "sokağı" (Maximum Margin) yaratacak en optimum hiper-düzlemi (Hyperplane) çizmektir.

Matematiksel olarak ifade etmek gerekirse, algoritma $\mathbf{w}^T \mathbf{x} + \mathbf{b} = 0$ denklemini sağlayan bir karar sınırı oluşturur. Burada $\mathbf{w}$ ağırlık vektörünü (yasaların katsayılarını), $\mathbf{b}$ ise sapma (bias) değerini temsil eder. Algoritmanın optimizasyon hedefi, sınırın iki tarafındaki en yakın veri noktalarına (Destek Vektörleri / Support Vectors) olan mesafeyi maksimize etmek için $1/2 \|\mathbf{w}\|^2$ değerini minimize etmektir. Kısacası SVM, partisinin merkezinden uzakta olan ve karşı partiye oy vermeye en yatkın olan "sınır bölgelerindeki" vekillere odaklanarak bu çizgiyi çeker. Parti çizgisinin çok derinlerinde olan sadık vekillerin, çizginin konumu üzerinde hiçbir matematiksel etkisi yoktur.

Grafik Analizi: SVM Sınır Çizgisinin Belirleyicileri



Bu grafik, Linear SVM modelinin Demokratlar ve Cumhuriyetçiler arasına çektiği geometrik sınırın (hiper-düzlemin) hangi yasalar tarafından inşa edildiğini göstermektedir. Grafikte ilk göze çarpan detay, "Doktor Ücretleri" (doktor_ucreti) tasarısının devasa mavi çubuğuyla sınırı tek başına domine etmesi ve partileri ayıran en keskin fay hattı olduğunu bir kez daha kanıtlamasıdır. Buna karşılık, "Sentetik Yakıt" (sentetik_yakit) ve "Bütçe Tasarısı" (butce_tasarisi) oylamaları uzun kırmızı çubuklarıyla karşı partinin geometrik sınır taşlarını oluşturmaktadır. Modelin marjın felsefesine göre bu katsayılar sıradan oylamaları değil, doğrudan iki parti arasındaki o ince ideolojik sınırdaki yer alan ve ayırmayı en çok tetikleyen kritik yasaları temsil eder. Ortadaki sıfır çizgisine çok yakın kalan yasalar ise ayrıştırıcı gücü zayıf olan, partiler üstü (bipartisan) uzlaşma alanlarıdır.

Veri Seti İçin Neden İyi Bir Seçimdir?

Yapay Sinir Ağlarının aksine, Linear SVM bu proje için yapısal olarak en iyi ve meşru modellerden biridir. Bunun temel nedenleri şunlardır:

- **Doğrusal Ayrılabilirlik (Linear Separability) Avantajı:** 1984 Kongre verisi, vekillerin katı parti disiplinleri sayesinde uzayda birbirine girmemiş, net bir şekilde iki bloğa ayrılmış bir yapıdadır. Linear SVM, sınıfların doğrusal olarak net bir şekilde ayrılabilmesi bu tarz yüksek boyutlu veri setlerinde endüstri standardıdır. Hiçbir karmaşık çekirdek hilesine (kernel trick) veya eğrisel bükülmelere (RBF kernel) ihtiyaç duymadan, dümdüz bir çizgi ile veriyi %99 başarıyla bölebilmektedir.
- **Gürültüye (Noise) ve Aykırı Değerlere Karşı Direnç:** Dış politika yasalarındaki 66 kişilik fire veya oylamalardaki "Çekimser" (0) oyları, veri setinde bir gürültü yaratmaktadır. SVM algoritması marjın optimizasyonu yaparken sadece destek vektörlerine (sınıra en yakın noktalara) odaklandığı için, verinin derinliklerindeki

aykırı oylardan veya sapan değerlerden minimum seviyede etkilenir. Bu yapısal direnç, modelin meclisteki isyankar vekillere rağmen ana ideolojik hattı kaybetmemesini sağlamıştır.

- **Yüksek Yorumlanabilirlik (White-Box Modeli):** Tıpkı Lojistik Regresyon gibi, Linear SVM (doğrusal çekirdek kullanıldığında) özellik önem derecelerini (coef_) doğrudan verebilmektedir. Bu sayede modelin sadece bir tahmin makinesi olarak kalmaması sağlanmış; hangi yasanın hiper-düzlemi ne kadar büktüğü sosyolojik olarak raporlanabilmiştir.

Özetle Linear SVM; projenin ihtiyaç duyduğu şeffaflığı koruyan, verinin doğrusal yapısıyla kusursuz bir uyum yakalayan ve meclisteki kutuplaşmayı en geniş "ideolojik marjin" ile haritalandırarak analizdeki yerini almıştır. Ancak yapısal sıkıntılarını göz ardı edemeyiz.

Nihai Model Seçimi: Olasılıksal Esneklik ve Lojistik Regresyonun Üstünlüğü


Yapılan sistematik analizler sonucunda hem Doğrusal Destek Vektör Makineleri (Linear SVM) hem de Lojistik Regresyon %99'luk üstün bir doğruluk (Accuracy) oranıyla birinciliği paylaşmıştır. Ancak sosyo-politik bir veri seti üzerinde nihai bir şampiyon belirlemek gerektiğinde, istatistiksel esnekliği ve analitik derinliği sebebiyle projenin ana modeli olarak Lojistik Regresyon seçilmiştir.

Bu tercihin temel nedeni, algoritmaların çıktı (output) felsefelerindeki farklılıktır. SVM, katı bir geometrik sınır çizerek vekili doğrudan "Demokrat" veya "Cumhuriyetçi" olarak etiketler (Hard Classification). Lojistik Regresyon ise Sigmoid fonksiyonu sayesinde bu tahmini olasılıksal bir düzleme taşır (Soft Classification). Modelin *"Bu vekilin Demokrat olma ihtimali %85, Cumhuriyetçi olma ihtimali %15'tir"* şeklinde bir çıktı üretebilmesi, siyaset biliminde muazzam bir yorumlama gücü sağlar. O %15'lik şüphe payı, katı parti disiplinine rağmen kendi bölgesinin veya vicdanının sesiyle hareket eden, iki parti arasında sıkışmış ılımlı (merkez) vekilleri tespit etmemize olanak tanır. Dolayısıyla Lojistik Regresyon, sadece keskin bir sınıflandırıcı değil, aynı zamanda siyasi aidiyetin derecesini ölçen olasılıksal bir tartı görevi gördüğü için bu çalışmanın nihai ve tek şampiyonu ilan edilmiştir.

Karmaşıklık Matrisi (Confusion Matrix) ve Hata Analizi: Tekil Sapmanın Anatomisi

Eğitim sürecinin ardından Lojistik Regresyon modelinin performansı, ayrılan %20'lik test seti (toplam 87 milletvekili) üzerinde test edilmiş ve sonuçlar Karmaşıklık Matrisi (Confusion Matrix) üzerinden görselleştirilmiştir. Elde edilen matris incelendiğinde, modelin 52 Demokrat vekili (True Negative) ve 34 Cumhuriyetçi vekili (True Positive) kusursuz bir şekilde doğru sınıflandırdığı görülmektedir. Toplam 87 tahminin 86'sında

başarılı olan algoritma, ~%99'luk üstün bir isabet oranına ulaşarak 1984 yılındaki Amerikan meclisinde yaşanan kutuplaşmanın keskinliğini matematiksel olarak ispatlamıştır.



Matristeki en dikkat çekici bulgu ise, modelin Cumhuriyetçi vekillerin oylarını analiz ederken hiçbir hata yapmamasına (False Negative = 0) karşılık, sadece 1 adet Demokrat vekili yanlışlıkla Cumhuriyetçi (False Positive = 1) olarak sınıflandırmasıdır. Bu tekil hata, makinenin istatistiksel bir başarısızlığı olmaktan ziyade, siyaset sosyolojisi açısından son derece anlamlı bir tespittir. Söz konusu o 1 vekil, resmi parti kimliği "Demokrat" olmasına rağmen oylamalarda Cumhuriyetçi Parti ile öylesine hizalanmıştır ki, model oy davranışlarına bakarak bu vekili doğrudan karşı partiye atamıştır. Bu durum, dönemin muhafazakar "Reagan" politikalarına destek veren ve parti çizgisine isyan eden merkez/sağ eğilimli Demokratların (Reagan Democrats) veri setine yansımış en somut örneği olarak değerlendirilmelidir. Lojistik Regresyon, yaptığı bu tek hata ile meclisteki resmi kimliklerle fiili oy davranışları arasındaki çelişkiyi deşifre etmeyi başarmıştır.

Sonuç ve Genel Değerlendirme:

Ockham'ın Usturası ve Politik İradenin İflası

Bu çalışma boyunca uygulanan makine öğrenmesi algoritmalarının sonuçları, hem veri biliminin doğasına hem de Amerikan siyaset sosyolojisine dair iki temel ve sarsıcı çıkarım sunmaktadır:

Modelsel Çıkarım (Ockham'ın Usturası): Algoritmaların performans karşılaştırmaları, makine öğrenmesi literatüründeki temel bir yanılgıyı çürütmektedir: "Daha karmaşık model, her zaman daha iyi sonuç vermez." Lojistik Regresyon ve Linear SVM gibi görece basit, doğrusal (linear) algoritmaların %99 gibi olağanüstü bir başarıya ulaşması, problemin Yapay Sinir Ağları (MLP) gibi derin ve karmaşık mimarilere ihtiyaç duymadığını kanıtlamıştır. Veri bilimi felsefesindeki "Ockham'ın Usturası" (Occam's Razor) prensibine uygun olarak; aynı başarıyı veren modeller arasında en basit ve en açıklanabilir olanı seçmek zorunluluktur. Bu veri setinde Doğrusal Modeller, sadece doğruluğuyla değil, sundukları şeffaf katsayı haritalarıyla "kara kutu" algoritmalarını mağlubiyete uğratmıştır.

Politik Çıkarım (Tahmin Edilebilirliğin Distopyası): İstatistiksel açıdan %99 doğruluk oranı muazzam bir başarı gibi görünse de, sosyoloji ve siyaset bilimi açısından bu durum "kutuplaşmanın" ve "özgür iradenin iflasının" matematiksel itirafıdır. Normal şartlarda insan davranışını ve politik vicdanı ölçen bir veri setinde bir miktar gürültü (noise) ve yüksek bir hata payı olması beklenir; çünkü insan karmaşıktır. Ancak bir bilgisayar algoritmasının, sadece birkaç yasa tasarısına bakarak bir milletvekilinin partisini %99 isabetle bilmesi, vekillerin artık kendi bölgelerinin çıkarlarına veya şahsi vicdanlarına göre değil; katı ve mekanik bir "parti disiplini" ile oy kullandıklarını gösterir. İnsanlar birer makine gibi oy verdiğinde, makinelerin insanları tahmin etmesi de kaçınılmaz olarak kusursuzlaşmaktadır. Karmaşıklık matrisinde tespit edilen o tekil hata (isyankar vekil), bu mekanik parti bloklaşmasının içinde hayatta kalmayı başarmış son bireysel irade kırıntısıdır.